

Herramienta Inteligente de Proyección de Canones de Arriendo de Propiedades

Propuesta de Valor Analítica y Despliegue de Aplicación Interactiva en Streamlit

Pamela Vidal Sierra

Máster en Data Science, Big Data & Business Analytics
Universidad Complutense de Madrid

17 de septiembre de 2026

Contenido

- 1 Introducción
- 2 Objetivos
- 3 Enfoque Técnico
- 4 Resultados
- 5 Aplicación Interactiva en Streamlit
- 6 Conclusiones y Comentarios Finales

- **Contexto:** En Chile, los contratos de arriendo se reajustan de forma periódica bajo índices atípicos y complejos —como la Unidad de Fomento (UF) o el Índice de Precios al Consumidor (IPC)—, un fenómeno financiero poco común a nivel internacional que busca proteger el valor del dinero en el tiempo, pero genera incertidumbre financiera en los hogares debido a la volatilidad macroeconómica.
- **Problema:** Las personas se enfrentan a una asimetría de información para anticipar y planificar cómo subirán sus canones de arriendo en el tiempo. Al no tener conocimiento de cómo funcionan los reajustes, pueden firmar contratos que son más perjudiciales que otros. Por ejemplo, con un reajuste mensual o trimestral.
- **Solución:** Una herramienta de educación y planificación financiera que traduce datos macroeconómicos complejos en proyecciones claras para el usuario final.

- **Objetivo General:** Desarrollar un sistema de gestión financiera para proyectar trayectorias inflacionarias y anticipar reajustes en contratos de arrendamiento.
- **Objetivos Específicos:**
 - Construir un dataset multivariante mediante ingesta de APIs oficiales (Banco Central de Chile).
 - Realizar un análisis exploratorio de datos (EDA) riguroso.
 - Desarrollar, entrenar y comparar distintos enfoques de modelado predictivo —desde series temporales clásicas hasta Machine Learning y Deep Learning— para optimizar la proyección del IPC.
 - Productivizar el modelo en una aplicación web funcional con Streamlit.

Ingeniería de Datos: Ingesta automatizada y creación de características para capturar la inercia inflacionaria.

Modelización Predictiva

Modelado de la incertidumbre presupuestaria y escenarios de reajuste mediante Simulación de Monte Carlo (P10, P50, P90) calibrada con el RMSE del modelo óptimo.

Técnicas evaluadas:

- **Benchmark de Mercado:** Encuesta de Expectativas Económicas (EEE).
- **Tradicionales:** Holt-Winters y SARIMA.
- **Machine Learning:** Ridge, Lasso, Elastic Net y Meta Prophet.
- **Avanzados y multivariados:** LightGBM (Direct Multistep), VAR-ML (LightGBM, XGB, CatBoost) y VAR-DL (TCN).

Categoría	Modelo	RMSE Global (%)
Benchmark de Mercado	EEE	0.3532
Tradicional	SARIMA	0.3553
Machine Learning	Lasso Regression	0.4016
Avanzados y multivariados	VAR-CatBoost OPTUNA	0.4117

Cuadro: Comparativa de RMSE Global, mejor modelo de cada categoría.

Estrategia Híbrida Seleccionada (12 meses)

- **Corto Plazo** ($h = 1$) : Benchmark **EEE** (información a un mes vista).
- **Mediano Plazo** ($h \geq 2$) : Modelo **SARIMA**.
- **Simulación Monte Carlo** → Escenarios **Realista** (P50), **Pesimista** (P90) y **Optimista** (P10), calibrados con el RMSE.
- **Resultado:** Motor de cálculo histórico automatizado según las condiciones definidas en el contrato.

- **Transformación de indicadores macroeconómicos abstractos en una herramienta directa de gestión patrimonial doméstica.**
 - Interfaz de usuario: Espacio donde el usuario ingresa los datos de su contrato (fecha de inicio, monto inicial, moneda y periodicidad de reajustes).
 - Visualización Dinámica: El sistema devuelve tanto el valor histórico reajustado como la proyección futura basada en la inflación estimada. Considerando 3 escenarios probables: Realista, Optimista y Pesimista. Es decir, montos asociados a una variación de IPC moderado, una variación realista y una variación sustantiva, respectivamente.

Despliegue Funcional

Herramienta *end-to-end* diseñada para que usuarios sin conocimientos financieros avanzados puedan tomar decisiones informadas ante la volatilidad del IPC.

Conclusiones y Comentarios Finales

- **Conclusión Principal:** Técnicamente es viable mitigar la asimetría de información doméstica mediante modelos predictivos orientados a la economía real.
- **Lecciones Aprendidas:**
 - **Flexibilidad e Iteración:** El desarrollo evidenció que la investigación en ciencia de datos es iterativa; la formulación inicial basada en regresión con cuantiles evolucionó hacia un enfoque estocástico más robusto (Montecarlo).
 - **Separación Metodológica:** desacoplar la predicción puntual (optimizado por RMSE) de la simulación de incertidumbre (Monte Carlo) permitió generar bandas P10, P50 y P90 eficientes sin sesgar la tendencia central.
 - El desarrollo exigió **alta tolerancia a la frustración y flexibilidad** ante los datos, evidenciando que el valor del TFM radica tanto en el resultado como en el aprendizaje mientras recorremos el camino (muchas veces, aleatorio).
- **Trabajos futuros:** Escalabilidad de la arquitectura hacia mercados regulados (ej. caso España), permitiendo incorporar restricciones normativas como topes legales de actualización y evaluar el impacto de la intervención estatal frente a la indexación libre presente en Chile.

¡A por la herramienta en acción!